

Введение

Автоматическое извлечение признаков позволит использовать неформализованные медицинские записи в системах поддержки принятия клинических решений, а так же как weak supervision для других моделей. В данной работе были проанализированы основные подходы в медицинском NLP, а наилучшие реализованы в виде модели multi-label классификации протоколов рентгенологических исследований органов грудной клетки.

Keywords: машинное обучение, вычислительная диагностика, NLP, СЭМД, нейросети.

Материалы & Методы

В качестве материалов использовались случайно извлеченные из ЕРИС протоколы: 4983 протокола для обучающей выборки, 507 - для тестовой. Распределение по патологиям представлено на рисунках 1 и 2:




Рис. 2: Обучающая выборка




Рис. 3: Тестовая выборка

Для очистки и коррекции использовались словари Open Office и OpenCorpora

Методы

- Модель, основанная на правилах
- Логистическая регрессия
- Random Forest
- Полносвязная нейронная сеть прямого распространения
- Рекуррентная нейронная сеть

Все вычисления производились на облачной платформе Google Colab

Этапы разработки системы

- Автоматизация очистки, коррекции и валидации текстов.
- Семантический анализ - выявление характерных языковых паттернов и закономерностей, свойственных представителям наиболее важных семантических групп и создание регулярных выражений, им соответствующих.
- Разработка и тестирование моделей, основанных на правилах.
- Настройка и тестирование различных моделей машинного обучения.
- Имплементация наилучших решений в ЕРИС.

Результаты 1 - Препроцессинг текстов

- Удалялись все символы, кроме букв и одиночных пробелов, отброшены незначимые лексемы (имена, адреса), все буквы приведены к нижнему регистру
- Исправлены грамматические ошибки алгоритмом Левенштайна. Эталонный словарь создан путем извлечения 397 медицинских терминов и сокращений из протоколов.
- Все слова в тексте приведены к лемме – нормальной форме слова.

Исходный текст
На рентгенограме огк в прямой проекции определяется незначительное снижение прозрачности в медиа-базальном сегменте, возможно пневмосклероз, признаков очаговых и инфильтративных изменений не обнаружено. Без патологий. Возрастные изменения легких Губкина 1-23

- Каждый текст представляется в виде вектора чисел, значения которых соответствуют количеству вхождений определенных паттернов, а каждое слово – эмбедингом (по контекстному окну 3 слова, размерность 16)
- Для решения проблемы дисбаланса классов удалялись частичные дубликаты, проводился oversampling алгоритмом SMOTE, а также аугментация текстов – генерация искусственных примеров путем замены части слов словами с близкими эмбедингами

Текст после обработки
на огк в прямой проекции определяется незначительное снижение прозрачности в медиабазальном сегменте возможно пневмосклероз признаков очаговых и инфильтративных изменений не обнаружено без патологии. Возрастные изменения легких

Будущие исследования

- Формализация СЭМД «Протокол инструментального исследования» в соответствии с клиническими областями

Результаты 2 - Создание и тестирование различных моделей

В данной работе были использованы как методы машинного обучения, так и экспертные модели, в таблице 1 проведено сравнение качества выделения одного из 8 классов - инфильтрации, наилучшие результаты показала нейронная сеть LSTM (рисунок 1)

Модель	Чувств.[CI95%],%	Спец.[CI95%],%
Logistic regression	83 [73; 89]	84 [80; 87]
Random Forest	78 [68; 86]	90 [86; 93]
Feed-forward NN	77 [67; 85]	88 [84; 91]
RNN (LSTM)	89 [80; 94]	99 [97; 99]
Rule-based model	84 [75; 90]	97 [94; 98]

Таблица 1: Сравнение различных подходов

Алгоритм	Match Exact Ratio	Accuracy
Rule-based	84 [81; 87]	97 [93; 100]
Rules+LSTM	87 [84; 90]	98 [94; 100]

Таблица 2: Оценка multi-label классификации

В таблице 2 описаны метрики качества выделения патологий итоговым алгоритмом, в который вошли 5 экспертных моделей (для выявления плеврального выпота, пневмоторакса, кальцинатов, расширения средостения, переломов ребер, кардиомегалии, диссеминации) и 2 нейросети LSTM - для выявления инфильтрации/консолидации и очагов затемнения. Класс «Норма» выделялся методом исключения - это единственный класс, исключаяющий все другие.

Выводы

- Выявлены языковые паттерны свойственные представителям наиболее важных нозологических групп и созданы регулярные выражения, им соответствующие: «Норма» - 27, «Плевральный выпот» - 4 паттерна, «Пневмоторакс» - 2, «Очаг затемнения» - 18, «Инфильтрация» - 16, «Диссеминация» - 2, «Полость» - 4, «Другое» - 6
- В процессе предобработки текстов создан словарь рентгенологических терминов и сокращений (397 слов), а на его основе разработан алгоритм коррекции грамматических ошибок в протоколах
- Совместно с экспертами разработаны правила (всего 86) для многозначной классификации протоколов рентгенологического исследования и оценена их эффективность (модель с наименьшей чувствительностью: «Плевральный выпот» - 80 [70; 88]%, модель с




Рис. 1: Матрица ошибок(слева) и ROC-кривая(справа) для класса «Инфильтрация/консолидация».

- Наибольшей чувствительностью : «Пневмоторакс» - 100 [87; 100]%)
- Проведена настройка и тестирование следующих моделей машинного обучения: логистическая регрессия, Random Forest, полносвязная нейронная сеть прямого распространения, рекуррентная нейросеть LSTM. Наилучшие результаты показала LSTM (для нозологических групп «Инфильтрация/консолидация» и «Очаг затемнения» чувствительность и специфичность составили соответственно 89 [80; 94]%, 99 [97; 99]% и 85 [70; 94]%, 99 [97; 99]%)
- Окончательный алгоритм реализован в виде программного кода и находится в процессе внедрения в Единую Радиологическую Информационную Систему города Москвы (ЕРИС)

Ссылки

[1] Базовые требования к работе ИИ сервисов: [Электронный ресурс] // ИИ сервисы в лучевой диагностике. URL: <https://mosmed.ai/documents/135>. (Дата обращения: 13.03.22)

Будущие исследования

- Формализация СЭМД «Протокол инструментального исследования» в соответствии с клиническими областями

- Создание базы эмбедингов для медицинских терминов
- Разработка русскоязычного аналога UMLS

Контакты

Email Ronzhin.Lev@endocrincentr.ru
Phone +7-977-853-36-73